СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ 4

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ 5

ВВЕДЕНИЕ 6
Актуальность темы 6
Степень разработанности темы 7
Объект и предмет исследования 8
Цель работы 8
Задачи исследования 8
Методы исследования 9
Научная новизна 9
Практическая значимость 9
Положения, выносимые на защиту 10
Апробация результатов 11
Структура работы 11

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ 12
1.1 Описание предметной области 12
1.2 Сущность решаемой проблемы 14
1.3 Обзор существующих подходов и решений 16
1.3.1 Постановка в рамках исследования операций 16
1.3.2 Постановка в рамках теории игр 18
1.3.3 Постановка в рамках рекомендательных систем с ограничениями 20
1.3.4 Постановка в рамках обучения с подкреплением 21
1.3.5 Постановка в рамках стохастической оптимизации 23
1.4 Обзор технологий и методов 24
1.4.1 Алгоритмы переранжирования с системными ограничениями 24
1.4.2 Методы обучения с подкреплением для рекомендательных задач 25

1.4.3 Параметрические симуляционные среды для рекомендательных систем ... 26
1.4.4 Подходы на основе больших языковых моделей и автономных агентов ... 27
1.5 Анализ ограничений существующих решений ... 28
1.6 Выводы по главе ... 30

2 МЕТОДЫ И ПОСТАНОВКА ЗАДАЧИ ... 31
2.1 Формализация задачи ... 31
2.1.1 Объекты и переменные задачи ... 31
2.1.2 Управляющая политика ... 32
2.1.3 Релевантность как функция близости ... 32
2.1.4 Отклик пользователя ... 33
2.1.5 Целевая функция управляющей стороны ... 34
2.1.6 Постановка как марковский процесс принятия решений с ограничениями ... 34
2.1.7 Связь с играми с перегрузкой ... 35
2.2 Требования к решению ... 36
2.2.1 Функциональные требования ... 36
2.2.2 Нефункциональные требования ... 37
2.2.3 Ограничения предметной области ... 38
2.3 Описание предлагаемого метода ... 38
2.3.1 Гибридная симуляционная среда ... 39
2.3.2 Множество сравниваемых рекомендательных политик ... 40
2.3.3 Двухслойная схема валидации ... 41
2.4 Сравнительный анализ альтернатив ... 42
2.4.1 Альтернатива 1. Чисто оптимизационный подход в рамках исследования операций ... 43
2.4.2 Альтернатива 2. Чисто теоретико-игровой подход ... 43
2.4.3 Альтернатива 3. Прямое обучение в LLM-агентной среде 43
2.4.4 Альтернатива 4. Прямое применение классических методов рекомендательных систем с ограничениями ... 44
2.5 Дизайн экспериментов и план валидации ... 45
2.5.1 Основные метрики оценки ... 45
2.5.2 Протокол сравнения политик ... 46

2.5.3 Исследование влияния отдельных компонентов и устойчивости 47
2.5.4 Итоговая валидация во втором слое 47
2.5.5 Критерии успешности работы 47
2.6 Выводы по главе 48

ЗАКЛЮЧЕНИЕ 49

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ВКР — выпускная квалификационная работа

GAP — обобщённая задача о назначениях (Generalized Assignment Problem)

LLM — большая языковая модель (Large Language Model)

MDP — марковский процесс принятия решений (Markov Decision Process)

MMR — ранжирование с максимальной маржинальной релевантностью (Maximal Marginal Relevance)

PPO — метод проксимальной оптимизации политики (Proximal Policy Optimization)

RL — обучение с подкреплением (Reinforcement Learning)

RLHF — обучение с подкреплением на основе обратной связи от человека (Reinforcement Learning from Human Feedback)

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Игра с перегрузкой — класс игр в теории игр, в которых полезность игрока на ресурсе зависит от числа других игроков, выбравших тот же ресурс

Калиброванные рекомендации — класс методов рекомендательных систем, обеспечивающих соответствие распределения рекомендованных позиций по категориям заданному эталонному распределению

Косинусная близость — мера сходства двух векторов, определяемая как косинус угла между ними

Марковский процесс принятия решений с ограничениями — расширение классического марковского процесса принятия решений, в котором политика максимизирует ожидаемую награду при дополнительных ограничениях, формулируемых как ожидания стоимостных функций

Обучение с подкреплением — класс методов машинного обучения, в которых агент учится принимать решения путём взаимодействия со средой и получения обратной связи в форме награды

Переранжирование — этап рекомендательного конвейера, на котором базовое ранжирование преобразуется с целью соблюдения дополнительных свойств выдачи

Политика — в обучении с подкреплением: отображение состояния среды в распределение вероятностей действий агента

Цена анархии — в теории игр: отношение стоимости наихудшего равновесия эгоистичных агентов к стоимости системного оптимума

ВВЕДЕНИЕ

Актуальность темы

Современные научно-практические IT-конференции — многодневные мероприятия с десятками параллельных сессий, в которых участвуют тысячи специалистов. Программа конференции включает доклады разной тематики, уровня и популярности; залы существенно различаются по вместимости. Распределение участников между параллельными сессиями определяет содержательную ценность мероприятия для участников, репутацию и коммерческую привлекательность мероприятия для организаторов и охват аудитории для докладчиков.

В отсутствие координирующего вмешательства распределение формируется как агрегат независимых индивидуальных выборов. Это приводит к одновременной перегрузке популярных залов, которые не могут вместить желающих, и хронической недозагрузке менее популярных, что снижает суммарное качество мероприятия. Прямое применение классических рекомендательных систем не решает задачи: оптимизируя индивидуальную релевантность независимо для каждого пользователя, такие системы воспроизводят одинаково популярные позиции в верхних строках выдачи и тем самым усиливают, а не ослабляют нагрузку на наиболее востребованные ресурсы.

Описанная задача относится к более широкому классу задач распределения автономных пользователей по ресурсам ограниченной вместимости через ненавязчивую рекомендательную подсказку. Этот класс задач возникает в маршрутизации транспортных потоков, управлении сервисами бронирования, образовательных платформах, управлении посетителями выставочных пространств. Несмотря на разнообразие приложений, существующие подходы не закрывают совокупности требований, характерной для рассматриваемой постановки: совместная оптимизация рекомендаций между пользователями, жёсткие ограничения вместимости в одной коллективной выдаче, ограниченность исторических данных, мягкий характер управляющего рычага.

Развитие рекомендательных систем, методов обучения с подкреплением и

симуляционных подходов с использованием больших языковых моделей в 2023–2026 годах расширило инструментарий, применимый к задачам этого класса. Подходы на основе генеративных агентов и LLM-симуляторов допускают работу с малыми каталогами при отсутствии исторических данных взаимодействий; методы обучения политики с ограничениями дают формальный аппарат для учёта системных ограничений вместимости. Систематический синтез этих подходов в задаче формирования программы конференции составляет содержание настоящей работы.

Степень разработанности темы

Задача в её обобщённой постановке исследовалась с разных сторон. В рамках теории игр аппарат игр с перегрузкой Розенталя [Rosenthal, 1973] и равновесия Уордропа [Wardrop, 1952] обеспечивают концептуальное описание ситуации децентрализованного выбора при взаимной зависимости пользователей. В рекомендательных системах подходы ранжирования с ограничениями Сингха и Йоахимса [Singh, Joachims, 2018] и калиброванных рекомендаций Стека [Steck, 2018] вводят аппарат учёта системных свойств выдачи. В обучении с подкреплением марковский процесс принятия решений с ограничениями [Altman, 1999] и его применения в производственных рекомендательных системах [Chen et al., 2019; Zheng et al., 2018] предоставляют операциональный механизм построения управляющей политики. Современные направления использования больших языковых моделей в роли симуляторов пользователей [Park et al., 2023; Zhang et al., 2024] и в роли ранжирующих компонентов [Hou et al., 2024] открывают возможность работы с малыми каталогами и качественной валидации моделей пользовательского поведения.

Вместе с тем, систематическое объединение указанных подходов применительно к задаче рассматриваемой структуры — формирование согласованных рекомендательных выдач для множества пользователей одновременно при жёстких ограничениях вместимости в одной коллективной выдаче — в открытой литературе отсутствует. Это определяет содержательное пространство для разработки методологического и алгоритмического подхода в работе.

Объект и предмет исследования

Объект исследования — процесс формирования персональных программ участников научно-практических IT-конференций при ограничениях вместимости параллельных сессий.

Предмет исследования — методы построения управляющей рекомендательной политики, согласующей индивидуальные предпочтения участников с системными ограничениями вместимости и обеспечивающей совместную оптимизацию рекомендаций между пользователями.

Цель работы

Цель работы — разработать интеллектуальную систему поддержки формирования программы конференции, учитывающую ограничения вместимости параллельных сессий и согласованность рекомендаций между участниками.

Задачи исследования

Для достижения поставленной цели в работе решаются следующие задачи:

1) Провести анализ предметной области, систематизировать существующие концептуальные рамки и методы решения задач рассматриваемого класса, выделить пробелы в существующих подходах.
2) Формализовать постановку задачи как марковский процесс принятия решений с ограничениями в структуре игры с перегрузкой; сформулировать функциональные и нефункциональные требования к разрабатываемому решению.
3) Разработать гибридную симуляционную среду для обучения и оценки рекомендательных политик в условиях отсутствия исторических данных взаимодействий, объединяющую однократную генерацию синтетической пользовательской популяции на основе большой языковой модели и параметрический пошаговый симулятор.
4) Реализовать набор сравниваемых рекомендательных политик различной природы — случайную, контентную на основе косинусной близости, эвристическую с учётом вместимости, основанную на алгоритме Maximal Marginal Relevance, обучаемую методом проксимальной оптимизации в постановке марковского процесса с ограничениями и опирающуюся на

большую языковую модель — и провести их сравнение по совокупности метрик качества.

5) Провести независимую валидацию политики, выбранной по результатам основного сравнения, в среде на основе автономных агентов с большими языковыми моделями; оценить разрыв между симуляцией и реальным поведением пользователей.

Методы исследования

Работа опирается на анализ литературы по рекомендательным системам, теории игр с перегрузкой, обучению с подкреплением и стохастической оптимизации; математическое моделирование задачи как марковского процесса принятия решений с ограничениями; разработку симуляционной среды с использованием параметрических моделей пользовательского выбора и генеративных агентов на основе больших языковых моделей; обучение политики методами обучения с подкреплением; статистическое сравнение результатов нескольких рекомендательных политик по совокупности метрик качества.

Научная новизна

Научная новизна работы заключается в систематическом синтезе элементов нескольких теоретических рамок применительно к задаче рассматриваемого класса. Конкретно: сочетание формализации задачи как марковского процесса принятия решений с ограничениями со структурным обоснованием через теорию игр с перегрузкой, использование гибридной симуляционной среды с однократной генерацией пользовательской популяции на основе большой языковой модели для решения задач с малым каталогом ресурсов, двухслойная схема валидации с независимой проверкой в среде на основе автономных агентов. Указанное сочетание адресует совокупность требований, не закрываемую ни одним из существующих подходов в отдельности.

Практическая значимость

Практическая значимость работы определяется применимостью разработанной системы к реальной задаче формирования программы конференций — на примере конференций Mobius и Heisenbug компании

JUG. Эмпирическая часть выполняется на материале открытых программ конференций Mobius и Heisenbug 2023–2025 годов (около 30–40 докладов на конференцию с описаниями тематики, форматов и распределением по тайм-слотам и залам); параметры симуляционной среды калибруются по фактической вместимости залов и типичной численности участников. Разработанные симуляционная среда и набор сравниваемых политик могут быть переиспользованы для решения задач смежных доменов, входящих в рассматриваемый класс: маршрутизация транспортных потоков, бронирование сервисов с ограниченной вместимостью, управление учебной нагрузкой в образовательных платформах, управление потоками посетителей в зонах с пропускными ограничениями.

Положения, выносимые на защиту

1) Постановка задачи формирования согласованных рекомендательных выдач при ограничениях вместимости как марковского процесса принятия решений с ограничениями в структуре игры с перегрузкой обеспечивает формальный аппарат для совместной оптимизации рекомендаций между пользователями при жёстких ограничениях вместимости в одной коллективной выдаче.
2) Гибридная симуляционная среда, объединяющая однократную генерацию пользовательской популяции на основе большой языковой модели с параметрическим пошаговым симулятором, обеспечивает обучаемость рекомендательной политики при отсутствии реальных данных взаимодействий и контролируемой стоимости вычислений.
3) Сравнительное исследование политик различной природы — случайной, контентной, эвристической с учётом вместимости, основанной на алгоритме MMR, обучаемой методом проксимальной оптимизации в постановке марковского процесса с ограничениями и опирающейся на большую языковую модель — позволяет систематически охарактеризовать компромиссы между соблюдением системных ограничений вместимости и пользовательской полезностью на материале рассматриваемой задачи.
4) Двухслойная схема валидации с проверкой выбранной политики во второй симуляционной среде на основе автономных агентов с большими

языковыми моделями позволяет оценить устойчивость результатов основного сравнения к смене модели пользовательского поведения и сформировать содержательную интерпретацию расхождений между двумя моделями симуляции.

Апробация результатов

Результаты работы получены и проверены на разработанной двухслойной симуляционной среде, объединяющей параметрический пошаговый симулятор и независимый слой валидации на основе автономных агентов с большими языковыми моделями. Подобная схема обеспечивает воспроизводимое сравнение методов и независимый контроль внешней валидности результатов. Постановка задачи и предлагаемый методологический подход обсуждались с научным руководителем работы и представителями команды разработки рекомендательного сервиса конференций Mobius и Heisenbug компании JUG, на материале которых выполняется эмпирическая часть работы.

Структура работы

Работа состоит из введения, четырёх глав, заключения, списка использованных источников и приложений. В главе 1 проводится анализ предметной области, систематизируются концептуальные рамки и методы, идентифицируется пробел в существующих подходах. В главе 2 формализуется постановка задачи, формулируются требования к решению, описывается предлагаемый метод и определяется дизайн экспериментальной части работы. В главе 3 представляются технические решения по реализации симуляционной среды и сравниваемых политик, описывается ход проведённых экспериментов. В главе 4 приводятся результаты сравнения политик, ablation studies, проверка устойчивости и итоговая валидация в среде на основе автономных агентов; обсуждается разрыв между симуляцией и реальным поведением. В заключении формулируются основные результаты работы и направления дальнейших исследований.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Описание предметной области

Класс рассматриваемых задач. В работе рассматривается класс задач распределения потока пользователей между ресурсами ограниченной вместимости при условии, что инструмент управления распределением — рекомендательная подсказка, не носящая принудительного характера. Цель управляющей стороны — максимизировать суммарную полезность распределения, не допуская при этом ни перегрузки отдельных ресурсов, ни их хронической недозагрузки.

Подобный класс задач возникает в широком спектре прикладных областей. К нему относятся задачи маршрутизации транспортных потоков, в которых навигационный сервис рекомендует водителям маршруты при ограниченной пропускной способности дорожной сети; задачи распределения мест в сервисах бронирования и заведениях обслуживания; задачи управления учебной нагрузкой при ограничениях на численность учебных групп; задачи управления потоками посетителей в зонах с ограниченной пропускной способностью (выставочные пространства, парки, конференции); задачи управления нагрузкой в распределённых вычислительных системах. Несмотря на различия в предметной специфике, перечисленные задачи объединены общей структурой: наличие неоднородного спроса со стороны автономных пользователей, ограниченность ресурсов, отсутствие возможности принудительного назначения и наличие управляющего рычага в виде рекомендательной выдачи.

Действующие стороны. В постановке задачи выделяются три стороны.

Пользователи — субъекты, самостоятельно принимающие решение о выборе ресурса. Множество пользователей характеризуется неоднородностью предпочтений и автономностью поведения.

Ресурсы — объекты выбора. Каждый ресурс характеризуется ограничением по числу пользователей, превышение которого приводит к деградации качества обслуживания: отказам в доступе, ухудшению опыта, снижению эффективности.

Организатор — управляющая сторона, заинтересованная в качестве

функционирования системы как целого. Не обладает полномочиями принудительного назначения; влияет на распределение исключительно через формирование рекомендательных подсказок — ранжированных списков, предъявляемых пользователю в качестве предпочтительных вариантов.

Особенности задачи. Управляющий механизм носит вероятностный характер: пользователь не обязан следовать рекомендации. Это отличает задачу от классических задач оптимального назначения, в которых решение управляющей стороны эквивалентно фактическому распределению.

Существенной особенностью является взаимосвязанность рекомендаций. Поскольку пользователи получают подсказки одновременно, рекомендация одному пользователю не может рассматриваться изолированно от рекомендаций, выдаваемых другим. При независимом формировании рекомендаций по индивидуальной релевантности множество пользователей получит в верхних позициях одни и те же объективно наиболее популярные ресурсы, что приведёт к ожидаемому совокупному потоку, превышающему вместимость. Следовательно, оптимальная индивидуальная подсказка для пользователя есть функция от распределения подсказок, выдаваемых остальным пользователям. Задача переходит в плоскость совместной оптимизации.

Полезность и противоречие интересов. Каждое сопоставление пользователя и ресурса характеризуется числовой оценкой полезности — степени соответствия ресурса предпочтениям пользователя с учётом контекстных факторов (времени, заполненности, удобства). Целевая функция организатора — суммарная полезность по всем парам «пользователь–ресурс», подлежащая максимизации при соблюдении ограничений вместимости.

Особенностью класса задач является системное противоречие между индивидуальной и совокупной оптимальностью. Индивидуальный выбор пользователей в пользу наиболее предпочтительного ресурса при отсутствии координации приводит к коллективному результату, заведомо уступающему оптимальному. Управляющая сторона решает задачу нивелирования данного противоречия: смещения индивидуального поведения в направлении системного оптимума при сохранении автономности пользователей.

Конкретная инстанция предметной области. В данной работе общий класс задач рассматривается на материале формирования программы научно-практических IT-конференций. Выбор инстанции обусловлен явной выраженностью характерных черт класса: значительной неоднородностью предпочтений участников, существенным разбросом вместимости параллельных сессий, отсутствием полной информации о пользователях, а также наличием доступа к экспериментальной площадке. Эмпирическая часть работы выполняется на данных конференций Mobius и Heisenbug компании JUG.

1.2 Сущность решаемой проблемы

Деградация системы при отсутствии управления. В отсутствие координирующего вмешательства распределение пользователей по ресурсам формируется как агрегат независимых индивидуальных выборов. Поскольку индивидуальные предпочтения неоднородны, но имеют общие пики (наиболее популярные позиции), результирующее распределение характеризуется одновременной перегрузкой части ресурсов и хронической недозагрузкой другой части. В терминах теории игр такое состояние — равновесие эгоистичных агентов, отстоящее от системного оптимума на величину, измеряемую показателем «цена анархии» (Price of Anarchy).

Структура потерь. Потери при подобном состоянии затрагивают всех участников взаимодействия. Конкретный их характер варьируется в зависимости от природы домена; ниже описаны категории, имеющие универсальный характер для всего рассматриваемого класса задач.

Пользователи, обращающиеся к перегруженным ресурсам, сталкиваются с отказами в обслуживании, увеличением времени ожидания, снижением качества обслуживания, отсутствием равноценных альтернатив в момент возникновения конфликта. Конкретное стоимостное выражение этих издержек определяется доменом: прямые денежные затраты, не компенсируемые получаемой полезностью; потеря времени; упущенные возможности; ухудшение качества предоставляемой услуги.

Управляющая сторона несёт потери, связанные с неэффективным использованием инфраструктурного капитала: затраты на обеспечение недозагруженных ресурсов не компенсируются объёмом фактического

использования. Снижение интегрального качества обслуживания одновременно отражается на показателях лояльности пользователей и продолжительности их участия в системе. При наличии у управляющей стороны коммерческих интересов, опосредованных распределением пользователей — например, интересов внешних партнёров, обусловленных охватом отдельных сегментов системы, — неравномерность распределения дополнительно снижает соответствующую коммерческую ценность.

В доменах, где роль поставщика ресурсов выделена как самостоятельная, поставщики недозагруженных ресурсов сталкиваются с обесцениванием своих ресурсов как канала распространения предоставляемого через них содержания. Это снижает мотивацию поставщиков к продолжению участия в системе и в долгосрочной перспективе ведёт к снижению разнообразия и качества предлагаемых ресурсов.

Несостоятельность прямого применения стандартных подходов. Прямое применение классической рекомендательной системы не решает поставленной задачи. Классическая рекомендательная система оптимизирует индивидуальную полезность пользователя на основании его предпочтений, не учитывая ограничений вместимости и взаимосвязанности рекомендаций. При одновременной выдаче рекомендаций множеству пользователей подобная система воспроизводит одинаково популярные позиции в верхних строках выдачи, тем самым усиливая, а не ослабляя нагрузку на наиболее востребованные ресурсы.

Альтернативная стратегия централизованного принудительного назначения также неприменима. С одной стороны, она входит в противоречие с автономностью пользователей и обесценивает само участие, основанное на свободе выбора. С другой стороны, формальное назначение не гарантирует фактического следования предписанию: реальное поведение пользователей сохраняет вероятностный характер вне зависимости от формы предъявления рекомендации.

Природа сложности задачи. Сложность задачи определяется одновременным выполнением трёх требований, каждое из которых разрешимо в отдельности, а в совокупности образующих противоречивую систему:

1) Соблюдение индивидуальной релевантности: каждая выдаваемая

рекомендация должна оставаться приемлемой для пользователя с точки зрения его предпочтений; в противном случае пользователь игнорирует подсказку.

2) Соблюдение ограничений вместимости: суммарный ожидаемый поток пользователей на каждый ресурс не должен превышать его вместимости.
3) Согласованность совокупной выдачи: множество персональных рекомендаций образует когерентное распределение; рекомендация одного пользователя учитывает рекомендации, выдаваемые другим.

Третье требование принципиально отличает задачу от классической постановки рекомендательных систем, в которой пользователи рассматриваются как независимые единицы анализа. В рассматриваемом классе задач пользовательские рекомендации становятся взаимозависимыми, что переводит задачу из множества независимых ранжирований в задачу совместной оптимизации с ограничениями. Объём пространства решений и вычислительная сложность возрастают при этом нелинейно с ростом числа пользователей и ресурсов.

Указанная взаимосвязанность представляет основной источник сложности задачи и обусловливает необходимость отдельного методологического подхода, не сводимого к прямому применению существующих методов классических рекомендательных систем.

1.3 Обзор существующих подходов и решений

Описанный в подразделах 1.1–1.2 класс задач допускает постановку в нескольких самостоятельных формальных рамках, каждая из которых предлагает собственный понятийный аппарат, классы алгоритмов и методические инструменты. Ниже последовательно рассматриваются пять рамок: исследование операций, теория игр, рекомендательные системы с ограничениями, обучение с подкреплением и стохастическая оптимизация. Рамки не являются взаимоисключающими: в практической работе они пересекаются и комбинируются. Конкретный методологический синтез, выбранный в работе, представлен в главе 2.

1.3.1 Постановка в рамках исследования операций

Исследование операций (Operations Research) рассматривает задачу как комбинаторную задачу распределения дискретных пользователей по

ограниченным ресурсам с целью максимизации суммарной полезности. Каноническая формулировка — обобщённая задача о назначениях (Generalized Assignment Problem, GAP), являющаяся классическим объектом изучения комбинаторной оптимизации.

Формальная постановка имеет следующий вид. Для множества пользователей $I = \{1, \ldots, n\}$, множества ресурсов $J = \{1, \ldots, m\}$, функции полезности u_{ij} и вместимостей c_j требуется найти бинарные индикаторы назначения $x_{ij} \in \{0, 1\}$, максимизирующие суммарную полезность $\sum_{ij} u_{ij} x_{ij}$ при условии однократного назначения каждого пользователя ($\sum_j x_{ij} = 1$ для всех i) и соблюдения вместимостей ($\sum_i x_{ij} \leq c_j$ для всех j). В случае, когда пользователю необходимо последовательно использовать несколько ресурсов в различные временные интервалы, постановка расширяется: ограничение однократного назначения заменяется условием, согласно которому в каждый момент времени за пользователем закреплено не более одного ресурса. Подобная расширенная формулировка относится к классу многопериодных задач о назначениях и пересекается с задачами составления расписаний (timetabling), для которых разработан самостоятельный методический аппарат.

С алгоритмической точки зрения GAP относится к классу NP-полных задач, что в общем случае исключает существование точного решения в полиномиальное время. Практически применяемые методы включают методы ветвей и границ для точного решения экземпляров умеренной размерности, лагранжеву релаксацию для построения оценок и приближённых решений [Fisher, Jaikumar, Van Wassenhove, 1986], а также эвристики на основе жадных алгоритмов и локального поиска. Систематический обзор алгоритмов представлен в работе Cattrysse и Van Wassenhove [1992]. Каноническим источником, охватывающим как задачи о рюкзаке, так и задачи о назначениях, является монография Martello и Toth [1990].

В прикладном плане аппарат исследования операций применяется в задачах распределения трудовых ресурсов (назначения работников на задачи с учётом нагрузки), в задачах распределения учащихся по образовательным группам, в задачах планирования производственных мощностей. В каждом из этих приложений решение задачи трактуется как итоговое распределение,

подлежащее исполнению.

Рамка исследования операций даёт строгий формализм и развитый алгоритмический арсенал. Применительно к рассматриваемой задаче ограничивается допущением о детерминированном исполнении решения: в постановке GAP $x_{ij} = 1$ означает фактическое назначение, тогда как в работе решение управляющей стороны имеет статус рекомендации с вероятностным откликом. Прямое применение GAP даёт решения, оптимальные в детерминированной модели, но не учитывающие отклика пользователей.

1.3.2 Постановка в рамках теории игр

Теория игр рассматривает задачу как ситуацию совместного принятия решений автономными агентами, каждый из которых преследует собственную выгоду, а коллективное распределение возникает как результат отдельных индивидуальных выборов. Естественной формальной рамкой для рассматриваемого класса задач является игра с перегрузкой (congestion game) — класс игр, в которых полезность игрока на ресурсе зависит от числа других игроков, выбравших тот же ресурс.

Каноническая формулировка дана Розенталем [Rosenthal, 1973]. Задаётся множество игроков N, множество ресурсов E и функция издержек $c_e : \mathbb{N} \to \mathbb{R}$ для каждого ресурса e, зависящая от числа игроков, выбравших этот ресурс. Стратегия игрока i — подмножество ресурсов $s_i \subseteq E$. Издержки игрока определяются как $\sum_{e \in s_i} c_e(n_e(s))$, где $n_e(s)$ — число игроков, использующих ресурс e в совместной стратегии s. Розенталем установлено, что любая такая игра обладает равновесием Нэша в чистых стратегиях и относится к классу точных потенциальных игр: существует единая функция потенциала $\Phi(s) = \sum_e \sum_{k=1}^{n_e(s)} c_e(k)$, монотонно изменяющаяся при любом одностороннем улучшении стратегии игрока. Концепция потенциальных игр впоследствии обобщена в работе Мондерера и Шэпли [Monderer, Shapley, 1996].

В задачах с большим числом однотипных пользователей, в которых индивидуальный вклад одного пользователя пренебрежимо мал по отношению к общему потоку, применяется непрерывная постановка, восходящая к работе Уордропа [Wardrop, 1952] о моделировании транспортных потоков. Согласно первому принципу Уордропа, в состоянии

равновесия все используемые маршруты между парой источник–назначение имеют одинаковую стоимость, не превышающую стоимости любого неиспользуемого маршрута. Второй принцип Уордропа описывает системно-оптимальное распределение, минимизирующее суммарные издержки. Разрыв между равновесием эгоистичных пользователей и системным оптимумом является центральной характеристикой задачи.

Количественная мера данного разрыва — показатель «цена анархии» (Price of Anarchy), введённый в работе Кутсупиаса и Пападимитриу [Koutsoupias, Papadimitriou, 1999] и определяемый как отношение стоимости наихудшего равновесия к стоимости системного оптимума. Для задач эгоистичной маршрутизации с линейными функциями задержек верхняя граница цены анархии составляет 4/3 [Roughgarden, Tardos, 2002]. Иллюстрацией непредсказуемости системного поведения при индивидуальном выборе служит парадокс Брэсса [Braess, 1968], показывающий, что добавление дополнительного маршрута в сеть может ухудшить равновесное распределение и увеличить издержки всех пользователей. Систематическое изложение результатов теории эгоистичной маршрутизации представлено в монографии Раугардена [Roughgarden, 2005].

В прикладном плане теоретико-игровая постановка наиболее активно используется в задачах маршрутизации транспортных потоков, в которых навигационные сервисы реализуют рассматриваемый сценарий непосредственно: каждый пользователь стремится минимизировать собственное время в пути, а заторы возникают как естественное следствие отсутствия координации между пользователями.

Теоретико-игровая рамка естественно соответствует природе задачи (автономные пользователи, децентрализованные решения, агрегатное распределение); аппарат равновесий и цены анархии даёт теоретическую базу для анализа устойчивых состояний системы. Применительно к управляющей задаче эта рамка остаётся описательной — она отвечает на вопрос, какое распределение установится, но не даёт алгоритма построения смещающего воздействия. Переход к проектированию управляющих воздействий относится к смежным направлениям (mechanism design, information design), не предоставляющим прямых вычислительных алгоритмов для рекомендательных задач.

1.3.3 Постановка в рамках рекомендательных систем с ограничениями

Подход рекомендательных систем рассматривает задачу как формирование индивидуального ранжированного списка для каждого пользователя на основании предсказанной полезности, при этом классическая постановка дополняется системными ограничениями на агрегированное распределение выдач. В отличие от классических задач ранжирования, оптимизирующих исключительно индивидуальную релевантность, постановки с ограничениями вводят дополнительные критерии, относящиеся к свойствам совокупной выдачи: соблюдение распределительных пропорций, сохранение справедливости по отношению к поставщикам ресурсов, соблюдение системных ограничений вместимости.

Ранжирование с ограничениями (constrained ranking) — формальная постановка, систематически разработанная в работах Сингха и Йоахимса [Singh, Joachims, 2018; 2019]. Политика ранжирования π, отображающая пользователя в распределение по позициям выдачи, оптимизируется с целью максимизации ожидаемой пользовательской полезности при дополнительных линейных ограничениях на агрегированную экспозицию ресурсов:

$$\max_{\pi} \mathbb{E}_u \left[\sum_i \pi_i(u) r_{ui} \right] \quad \text{при} \quad \sum_u \pi_i(u) \in [c_i^{\min}, c_i^{\max}] \; \forall i,$$

где r_{ui} — предсказанная релевантность ресурса i для пользователя u, а $c_i^{\min}, c_i^{\max}$ — нижние и верхние границы совокупной экспозиции ресурса i. Авторами показано, что задача допускает эффективное решение методами линейного программирования и применима как для оптимизации справедливости экспозиции, так и для соблюдения системных ограничений на распределение.

Калиброванные рекомендации (calibrated recommendations), предложенные Стеком [Steck, 2018], представляют альтернативную перспективу: для каждого пользователя распределение рекомендованных ресурсов по категориям должно соответствовать его историческому профилю. Постановка опирается на минимизацию расхождения Кульбака–Лейблера между распределением рекомендаций и пользовательским профилем как

дополнительного слагаемого в целевой функции. Хотя задача калибровки сформулирована на уровне индивидуальной выдачи, аппарат расхождения распределений применяется для измерения системных свойств совокупной выдачи, в том числе равномерности заполнения ресурсов.

Концепция справедливости со стороны поставщиков (provider-side fairness) разработана в направлении исследований многосторонних рекомендательных систем [Abdollahpouri, Burke, Mobasher, 2020]. В её рамках в качестве заинтересованных сторон признаются не только пользователи, но и поставщики ресурсов, ожидающие равномерного или пропорционального распределения внимания. Классические работы данного направления включают Биегу, Гуммади и Вайкума [Biega, Gummadi, Weikum, 2018] о равенстве внимания (equity of attention), Целике и соавторов [Zehlike et al., 2017] о справедливом ранжировании FA*IR, а также позднейшие обзоры [Naghiaei, Rahmani, Deldjoo, 2022], систематизирующие подходы к учёту провайдерских интересов в системах ранжирования.

В прикладном плане рекомендательные системы с ограничениями применяются в стриминговых сервисах для управления экспозицией содержания (Netflix, Spotify), в торговых площадках для распределения внимания между продавцами, в задачах формирования ленты социальных сетей для управления разнообразием выдачи.

Рекомендательная рамка даёт развитый аппарат операциональных метрик (NDCG, MRR, ILD, метрики калибровки и справедливости экспозиции) и алгоритмы переранжирования, применимые поверх базовой модели релевантности. Главное ограничение для рассматриваемой задачи — формулировка ограничений как математического ожидания по распределению пользователей (выравнивание «в среднем» по большому потоку выдач), тогда как в работе требуется соблюдение вместимости в каждой конкретной коллективной выдаче. Адаптация классических методов под одноразовый совместный режим требует существенных модификаций.

1.3.4 Постановка в рамках обучения с подкреплением

Подход обучения с подкреплением (reinforcement learning, RL) рассматривает задачу как последовательный процесс взаимодействия между управляющей политикой и пользователями, в котором политика формирует рекомендательные подсказки, наблюдает отклик и адаптирует своё

поведение на основании накопленного опыта взаимодействия. В отличие от подходов, оптимизирующих заранее зафиксированную целевую функцию на статической модели предпочтений, рамка обучения с подкреплением позволяет обучать политику непосредственно из взаимодействий с пользователями или их моделью, учитывая отложенные эффекты решений и динамику пользовательского поведения.

Каноническая формализация — марковский процесс принятия решений (Markov Decision Process, MDP). Управляющий агент в каждом шаге наблюдает состояние s_t (контекст пользователя, история взаимодействия, состояние системы), выбирает действие a_t (рекомендацию или ранжированный список), получает мгновенную награду r_t (показатель полезности — клик, удовлетворение, продолжительность взаимодействия) и переходит в новое состояние s_{t+1} согласно вероятности перехода $P(s_{t+1}|s_t, a_t)$. Целью является нахождение политики π, максимизирующей дисконтированную суммарную награду $\mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t\right]$.

Постановка задачи с ограничениями — марковский процесс с ограничениями (Constrained MDP), систематически разработанная в монографии Альтмана [Altman, 1999]. К стандартной MDP добавляется вектор стоимостных функций $c_1, \ldots, c_k$; ограничения принимают вид $\mathbb{E}_\pi \left[\sum_t \gamma^t c_{i,t}\right] \leq d_i$. Альтманом доказано существование оптимальной стационарной стохастической политики и сводимость задачи к линейному программированию на пространстве распределений по парам «состояние–действие». В терминах рассматриваемого класса задач функции c_i соответствуют ограничениям вместимости ресурсов, а пороговые значения d_i — допустимой загрузке.

В качестве промежуточной рамки между классическим обучением с подкреплением и комбинаторной оптимизацией используются многорукие бандиты с ограничениями ресурсов (bandits with knapsacks), формализованные в работах Баданидиюру и соавторов [Badanidiyuru et al., 2013]. В этой постановке каждый раунд рассматривается как одно взаимодействие с пользователем без учёта долгосрочных переходов состояний, а глобальные ограничения формулируются как ограничения на суммарное потребление ресурсов. Линейная контекстная версия задачи [Agrawal, Devanur, 2016] обеспечивает алгоритмы с гарантированной

верхней оценкой сожаления порядка $\tilde{O}(\sqrt{T})$.

Применение обучения с подкреплением в рекомендательных системах развивается с середины 2000-х; современный этап представлен работами о глубоком обучении с подкреплением для рекомендаций [Zheng et al., 2018], производственным применением метода REINFORCE с коррекцией смещения вне политики на крупной видеоплатформе [Chen et al., 2019] и систематическими обзорами направления [Afsar et al., 2022]. Постановки с ограничениями получили развитие в работе [Zheng et al., 2022] и в технических отчётах индустриальных лабораторий [Netflix Tech Blog, 2022], демонстрирующих жизнеспособность подхода в промышленных условиях. Большинство открытой литературы опирается на массивные объёмы накопленных данных взаимодействий, обеспечивающие надёжное оффлайн-обучение и валидацию методами оценки вне политики.

Рамка обучения с подкреплением учитывает динамику взаимодействия и отложенные эффекты решений; марковский процесс с ограничениями обеспечивает формальную базу учёта системных ограничений. Для рассматриваемой задачи характерны два ограничения. Первое — высокие требования к объёму данных: производственные применения опираются на миллионы взаимодействий, что недоступно при малом каталоге; следствие — необходимость симулятора пользовательского поведения и перенос части валидационной нагрузки в плоскость качества симулятора. Второе — формулировка ограничений как математического ожидания по политике, означающая, как и в рекомендательной рамке, выравнивание «в среднем», а не соблюдение требований в каждой коллективной выдаче.

1.3.5 Постановка в рамках стохастической оптимизации

Подход стохастической оптимизации рассматривает задачу с явным учётом случайности пользовательского поведения. Каноническими формулировками являются двухэтапное стохастическое программирование [Birge, Louveaux, 2011], в котором решение принимается в условиях неопределённости и корректируется после её раскрытия; вероятностные ограничения [Charnes, Cooper, 1959], формулируемые как требования на вероятность нарушения; робастная оптимизация [Ben-Tal, El Ghaoui, Nemirovski, 2009], дающая гарантии работоспособности по наихудшему сценарию. Прикладным образцом служит область управления доходностью

(revenue management) [Talluri, van Ryzin, 2004], структурно близкая к рассматриваемой задаче.

В настоящей работе стохастическая рамка не выступает основным методологическим аппаратом; элементы вероятностного описания используются в формализации задачи (раздел 2.1), но операциональным механизмом построения политики выбран марковский процесс принятия решений с ограничениями. Высокая вычислительная сложность точных стохастических постановок и необходимость в данных для оценивания распределения спроса ограничивают их прямое применение в условиях малого каталога ресурсов и отсутствия исторических данных взаимодействий.

1.4 Обзор технологий и методов

Если в подразделе 1.3 систематизированы концептуальные рамки постановки задачи, то здесь приводится обзор конкретных алгоритмов, моделей и подходов, разработанных в литературе и индустрии. Цель — определить инструментарий, доступный для непосредственного использования или адаптации, и оценить его применимость с учётом специфики: малый каталог ресурсов, отсутствие исторических данных взаимодействий, требование соблюдения ограничений в одноразовой коллективной выдаче. Обзор проводится по четырём направлениям: алгоритмы переранжирования с системными ограничениями (1.4.1), методы обучения с подкреплением для рекомендательных задач (1.4.2), параметрические симуляционные среды (1.4.3), подходы на основе больших языковых моделей и автономных агентов (1.4.4).

1.4.1 Алгоритмы переранжирования с системными ограничениями

Переранжирование — наиболее доступный класс инструментов учёта системных ограничений в рекомендательной выдаче: к базовому ранжированию по индивидуальной релевантности применяется преобразование, обеспечивающее заданные свойства совокупного результата (разнообразие, справедливость, баланс категорий, ограничения вместимости). Базовая модель не переобучается, что упрощает внедрение в существующие системы.

Канонические алгоритмы класса включают Maximal Marginal Rele-

vance [Carbonell, Goldstein, 1998] — жадный метод балансирования релевантности и разнообразия через параметр λ; детерминантные точечные процессы [Kulesza, Taskar, 2012], выбирающие подмножество с вероятностью, пропорциональной определителю подматрицы ядра, что штрафует похожие элементы; алгоритм FA*IR [Zehlike et al., 2017] для справедливого формирования top-k выдачи с гарантиями представления защищённой группы; алгоритм калиброванных рекомендаций [Steck, 2018], минимизирующий расхождение Кульбака–Лейблера между распределением выдачи по категориям и заданным эталонным распределением. Последний наиболее близок к задачам соблюдения распределительных ограничений на уровне коллективной выдачи: при надлежащем определении эталона аппарат расхождения распределений непосредственно применим к контролю заполненности ресурсов.

Общее ограничение алгоритмов переранжирования применительно к рассматриваемой задаче — их статический характер. Алгоритм оптимизирует выдачу при заданных предположениях о пользовательском поведении, но не учитывает вероятностного отклика и взаимной зависимости рекомендаций между пользователями; распространение на коллективную оптимизацию требует существенных обобщений, выходящих за рамки оригинальных постановок.

1.4.2 Методы обучения с подкреплением для рекомендательных задач

Методы обучения с подкреплением, применяемые в рекомендательных системах, делятся на три семейства: основанные на функции ценности (Q-обучение [Watkins, Dayan, 1992] и его глубокая версия DQN [Mnih et al., 2015], применённая в DRN [Zheng et al., 2018] для рекомендации новостей); основанные на политике (REINFORCE [Williams, 1992]); гибридные методы «актор-критик» (A2C/A3C [Mnih et al., 2016] и PPO [Schulman et al., 2017]). Семейство «актор-критик» естественно интегрируется с задачами с ограничениями через двойственную оптимизацию множителей Лагранжа [Zheng et al., 2022].

Производственные применения опираются на накопленные журналы взаимодействий и требуют методов компенсации смещения между обучающей и целевой политиками — выборки по значимости (importance sampling) и её устойчивых вариантов, а также методов дважды робастной

оценки. Работа Чена и соавторов [Chen et al., 2019] предложила Top-K коррекцию вне политики для метода REINFORCE, обеспечив развёртывание обучаемой политики в крупной производственной системе.

В рассматриваемой задаче прямое применение обучения с подкреплением осложнено отсутствием накопленных журналов взаимодействий: малый объём исторических данных делает методы оценки вне политики ненадёжными. Альтернативой служит обучение и оценка политик в симуляционной среде (подраздел 1.4.3).

1.4.3 Параметрические симуляционные среды для рекомендательных систем

При недоступности достаточных объёмов накопленных данных взаимодействий и невозможности масштабных онлайн-экспериментов основным альтернативным источником данных служит симуляционная среда, моделирующая поведение пользователей в ответ на рекомендательные политики. Параметрический класс симуляторов задаёт поведение через явно специфицированные вероятностные функции выбора; альтернативный класс на основе больших языковых моделей рассматривается в подразделе 1.4.4.

Каноническими представителями класса являются RecSim [Ie et al., 2019] (Google; модель пользователя с латентным состоянием, моделями выбора и интеграцией с библиотеками обучения с подкреплением); Sim4Rec [Sber AI Lab, 2022] (открытая разработка ПАО «Сбер», ориентированная на автономные эксперименты с поддержкой синтетической генерации пользователей и моделей выбора, имеющая документацию на русском языке); KuaiSim [Zhao et al., 2023] (среда исследовательской группы Kuaishou с поведенческой моделью, обученной на журналах производственной системы) с сопровождающим набором полностью наблюдаемых данных KuaiRec [Gao et al., 2022].

Параметрические симуляционные среды применимы к рассматриваемой задаче, однако сопровождаются известными методологическими оговорками: разрыв между симулируемым и реальным поведением пользователей (sim-to-real gap) ставит вопрос внешней валидности; сам симулятор содержит содержательные предположения о поведении, требующие явного обоснования; при использовании среды как основной

площадки сравнения методов необходима независимая проверка устойчивости результатов к выбору параметров.

1.4.4 Подходы на основе больших языковых моделей и автономных агентов

В 2023–2026 годах сформировался самостоятельный класс подходов, основанных на использовании больших языковых моделей (large language models, LLM) и автономных агентов на их базе. В отличие от параметрических методов, агентный подход возлагает функцию принятия решений на экземпляр LLM, получающей описание персоны пользователя в естественном языке. Большая языковая модель может выступать также в роли ранжирующего компонента, генератора синтетических данных, инструмента оценки качества или элемента контура обучения.

В роли симуляторов пользователей идея восходит к работе о генеративных агентах [Park et al., 2023] и развивается в серии работ для рекомендательного домена — Agent4Rec [Zhang et al., 2024], AgentCF, RecAgent — а также в крупномасштабных средах OASIS [Yang et al., 2024] и AgentSociety [Piao et al., 2025], моделирующих миллионы агентов в социальных и городских контекстах.

В роли ранжирующего компонента современные LLM способны выполнять ранжирование без дополнительного обучения (zero-shot) [Hou et al., 2024], интегрируясь поверх существующих систем поиска по эмбеддингам. Семейство методов LLMRec, P5, GPT4Rec и ChatRec, а также свежие подходы BIGRec [Bao et al., 2024] и LLaRA [Liao et al., 2024] исследуют разные способы использования LLM в задачах рекомендации — от прямой генерации списков до гибридных архитектур, объединяющих эмбеддинги традиционных рекомендательных моделей с языковыми моделями. Агентные рекомендательные системы развивают подход через паттерны ReAct [Yao et al., 2022] и Reflexion.

В задачах генерации синтетических данных и оценки качества LLM применяются для создания пользовательских профилей и сценариев поведения, что особенно ценно для задач с малым каталогом ресурсов. Парадигма LLM-as-judge [Zheng et al., 2023] обеспечивает ускоренную автономную оценку рекомендательных политик без дорогостоящих пользовательских исследований.

Гибридные схемы комбинируют преимущества обоих классов: однократная LLM-генерация персон с последующим использованием в параметрическом симуляторе существенно снижает совокупную вычислительную стоимость при сохранении содержательного разнообразия популяции. Двухслойная валидация — обучение в параметрическом симуляторе и независимая проверка в LLM-агентной среде — согласует требования эффективности и достоверности результатов. Главные ограничения подхода — вычислительная стоимость прямого использования LLM на каждом шаге и вопрос соответствия поведения LLM-агентов поведению реальных пользователей, активно обсуждаемый в свежей литературе.

1.5 Анализ ограничений существующих решений

Систематизация рассмотренных в подразделах 1.3–1.4 концептуальных рамок, методов и инструментов позволяет выделить ключевые ограничения существующих подходов. Анализ проводится по нескольким независимым осям, каждая из которых отражает важное свойство задачи, недостаточно покрываемое существующей литературой.

Ось 1. Совместная оптимизация рекомендаций между пользователями. Большинство рамок рассматривают задачу на уровне индивидуального пользователя; постановка, в которой множество пользователей одновременно требуют согласованной выдачи, представлена лишь в исследовании операций и в специализированных постановках управления доходностью, причём первое не учитывает вероятностного отклика.

Ось 2. Жёсткие ограничения вместимости в одноразовой выдаче. Подходы рекомендательных систем с ограничениями и постановки Constrained MDP формулируют ограничения как математическое ожидание по распределению пользователей или по политике, что обеспечивает выравнивание «в среднем» по большому потоку выдач, но не соблюдение в каждой конкретной коллективной выдаче, требуемое в рассматриваемой постановке.

Ось 3. Ограниченность исторических данных. Производственные применения опираются на миллионы накопленных взаимодействий; в задачах с малым каталогом и ограниченным числом пользователей подобный объём данных принципиально недоступен, что исключает прямое

применение методов обучения с подкреплением и методов оценки вне политики.

Ось 4. Природа управляющего рычага. Классические постановки покрывают полярные случаи — либо детерминированное исполнение, либо отсутствие управляющего воздействия. Промежуточный случай мягкой рекомендации, которой пользователь может не следовать, формализован слабее; смежные направления (mechanism design, information design) развиты для теоретического анализа и не предоставляют прямых вычислительных алгоритмов.

Ось 5. Симуляционная валидация при ограниченных данных. Параметрические симуляторы (RecSim, Sim4Rec, KuaiSim) ориентированы на сценарии с большими каталогами и параметрическими моделями предпочтений, что несёт риск упрощения при малом каталоге. LLM-агентные симуляторы (подраздел 1.4.4) дают содержательную глубину, но сопровождаются высокой вычислительной стоимостью и открытым вопросом соответствия реальному поведению пользователей.

Идентифицированный пробел. Объединение перечисленных осей формирует область, систематически не покрытую существующими решениями: задача формирования согласованных рекомендательных выдач для множества пользователей одновременно, с жёсткими ограничениями вместимости в каждой одноразовой выдаче, при ограниченных исторических данных, в условиях мягкого характера управляющего рычага и при необходимости опоры на симуляционную валидацию. Привлечение средств LLM-агентного аппарата (подраздел 1.4.4) существенно расширяет возможности работы с осями 3 и 5 (ограниченность данных и симуляционная валидация), однако само по себе не закрывает оси 1 и 2 (совместная оптимизация и жёсткие ограничения вместимости в одноразовой выдаче). Ни одна из рассмотренных концептуальных рамок и ни один из существующих программных инструментов — включая инструменты, основанные на больших языковых моделях, — не предоставляет готового решения для указанного пересечения требований; работы, систематически адресующие все пять осей одновременно, в открытой литературе на момент проведения исследования не обнаружены. Этот пробел определяет содержательное пространство для разработки методологического и

алгоритмического подхода в работе; конкретное наполнение пространства представлено в главе 2.

1.6 Выводы по главе

Рассматриваемый класс задач — распределение автономных пользователей по ресурсам ограниченной вместимости через рекомендательную подсказку, не носящую принудительного характера, — возникает в широком спектре прикладных областей и образует устойчивую предметную постановку. Конкретной инстанцией работы выбрано формирование программы научно-практических IT-конференций.

Сложность задачи определяется одновременным выполнением трёх требований: соблюдения индивидуальной релевантности рекомендаций, соблюдения ограничений вместимости ресурсов и согласованности совокупной выдачи между пользователями. Прямое применение классических рекомендательных систем эту задачу не закрывает, поскольку независимая оптимизация индивидуальной полезности усиливает, а не ослабляет нагрузку на наиболее востребованные ресурсы.

Среди существующих концептуальных рамок ни одна не покрывает совокупности характерных для задачи требований. Аппарат исследования операций ограничен предположением о детерминированном исполнении решения; классическая теория игр носит описательный, а не предписывающий характер; постановки рекомендательных систем с ограничениями формулируют ограничения как амортизированные ожидания, а не как требования к одной выдаче; методы обучения с подкреплением требуют объёмов данных, недоступных в условиях малого каталога; стохастическая оптимизация не предоставляет операциональной схемы построения управляющей политики. Аналогичный вывод получен для рассмотренных алгоритмов и симуляционных сред — ни один из готовых инструментов не закрывает специфики задачи без существенной адаптации.

Идентифицированный пробел, описанный в подразделе 1.5, определяет содержательное пространство работы. В главе 2 формализуется постановка задачи и описывается предлагаемый методологический подход, опирающийся на синтез аппарата марковского процесса принятия решений с ограничениями и теории игр с перегрузкой.

2 МЕТОДЫ И ПОСТАНОВКА ЗАДАЧИ

2.1 Формализация задачи

В подразделе 1.5 идентифицирован пробел в существующих решениях, относящийся к задаче формирования согласованных рекомендательных выдач для множества пользователей одновременно при жёстких ограничениях вместимости. Настоящий подраздел представляет формальную постановку задачи, опирающуюся на синтез двух концептуальных рамок, рассмотренных в подразделах 1.3.2 и 1.3.4: теории игр с перегрузкой (congestion games) и марковского процесса принятия решений с ограничениями (Constrained MDP). Первая рамка обеспечивает структурное описание ситуации, в которой коллективное распределение пользователей формируется как результат децентрализованных индивидуальных выборов под влиянием информационного сигнала; вторая — операциональный аппарат для построения управляющей политики, обучаемой методами обучения с подкреплением.

2.1.1 Объекты и переменные задачи

Рассматривается дискретное множество ресурсов, обозначаемых индексом из множества $J = \{1, \ldots, m\}$, и дискретное множество пользователей с индексами из множества $I = \{1, \ldots, n\}$. Каждый ресурс j характеризуется вместимостью c_j, представляющей предельное число пользователей, для которых обслуживание ресурсом возможно без деградации качества. Каждый пользователь i характеризуется профилем p_i — описанием его интересов в форме, поддерживающей численное вычисление меры близости с описаниями ресурсов; в работе профиль представлен векторным эмбеддингом текстового описания интересов, согласованным по размерности с эмбеддингами описаний ресурсов.

Время рассматривается дискретно: эпизод взаимодействия пользователей с системой разбивается на тайм-слоты $T = \{1, \ldots, \tau\}$, в каждом из которых пользователю предъявляется рекомендательная подсказка и наблюдается фактический выбор. В пределах одного тайм-слота пользователь может быть сопоставлен не более чем с одним ресурсом; полный план взаимодействия

пользователя с системой за эпизод формируется как последовательность сопоставлений по тайм-слотам.

2.1.2 Управляющая политика

Управляющая сторона реализует политику рекомендаций π, отображающую состояние системы в распределение возможных рекомендательных выдач. На каждом тайм-слоте t для каждого пользователя i политика формирует ранжированный список $L_{i,t}$ из K ресурсов, отсортированных в порядке убывания предсказанной полезности. Список $L_{i,t}$ является непосредственным управляющим воздействием на пользователя; пользователь самостоятельно принимает решение о выборе ресурса, опираясь на представленный список и собственные предпочтения.

Существенным элементом постановки является зависимость рекомендации одного пользователя от рекомендаций, выдаваемых остальным пользователям в тот же тайм-слот. Формирование списка $L_{i,t}$ изолированно от $\{L_{j,t}\}_{j \neq i}$ воспроизводит классическую постановку индивидуальных рекомендательных систем и приводит, как показано в подразделе 1.2, к коллективным эффектам перегрузки. В рамках предлагаемой формализации политика π принимает на вход агрегированное состояние системы, включающее текущую загрузку ресурсов, что обеспечивает информационную связность рекомендаций между пользователями.

2.1.3 Релевантность как функция близости

Полезность сопоставления пользователя i с ресурсом j определяется через меру семантической близости между профилем пользователя и описанием ресурса. Используется косинусная близость векторных эмбеддингов:

$$r_{ij} = \cos(p_i, e_j) = \frac{p_i \cdot e_j}{\|p_i\| \cdot \|e_j\|},$$

где p_i — эмбеддинг профиля пользователя, e_j — эмбеддинг описания ресурса. Выбор косинусной близости в качестве функции релевантности обусловлен её интерпретируемостью, низкой вычислительной стоимостью и широким распространением в качестве базового сигнала ранжирования в литературе рекомендательных систем.

Чисто семантическая близость в роли сигнала релевантности порождает известную проблему filter bubble — систематическое получение

пользователем рекомендаций лишь тематически близких ресурсов. В работе эта проблема решается не на уровне определения релевантности, а на уровне сравниваемых политик: часть из них (в частности, MMR и LLM-ranker) предусматривают механизмы повышения тематического разнообразия выдачи, что позволяет провести систематическое сравнение в этом отношении.

2.1.4 Отклик пользователя

Ответ пользователя i на рекомендательный список $L_{i,t}$ моделируется как случайная величина $y_{i,t}$, принимающая значения из множества $J \cup \{\varnothing\}$, где значение $\varnothing$ соответствует отказу от выбора в данном тайм-слоте. Распределение $y_{i,t}$ задаётся условной вероятностной функцией выбора $P(y_{i,t} \mid L_{i,t}, p_i, s_t)$, зависящей от рекомендательного списка $L_{i,t}$, профиля пользователя p_i и текущего состояния системы s_t (в первую очередь — текущей заполненности ресурсов). Вероятностный характер отклика отражает фундаментальное ограничение управляющего рычага: рекомендация формирует пользовательскую перцепцию доступных вариантов, но не предопределяет фактического выбора. Базовая функция выбора — мультиномиальная логит-модель с температурой: вероятность выбора ресурса пропорциональна экспоненте релевантности с учётом штрафа за заполненность, отказ представлен отдельной альтернативой с базовой вероятностью; точные параметры приводятся в главе 3.

Все компоненты совокупной награды рассчитываются по реализациям случайных величин $\{y_{i,t}\}$, а не по содержанию рекомендательных списков $\{L_{i,t}\}$: компонент пользовательской полезности агрегирует релевантности $r_{i,y_{i,t}}$ для тех пользователей и тайм-слотов, в которых $y_{i,t} \neq \varnothing$; мера переполнения и дисперсия заполненности рассчитываются по фактическому распределению пользователей по ресурсам, индуцированному реализациями $\{y_{i,t}\}$. Состояние s_t, наблюдаемое политикой на каждом шаге, аналогично формируется по реализациям $y_{i,t}$ для пользователей, обработанных ранее в текущем тайм-слоте. Тем самым проигнорированная пользователем рекомендация не приносит положительного вклада в полезность и не уменьшает наблюдаемой загрузки альтернативных ресурсов, что естественным образом штрафует политику за выдачу рекомендаций, не согласованных с предпочтениями пользователя.

2.1.5 Целевая функция управляющей стороны

Целью управляющей стороны является максимизация совокупного результата эпизода, агрегирующего три компонента: суммарную пользовательскую полезность выбранных ресурсов, минимизацию переполнений вместимости, минимизацию неравномерности загрузки ресурсов. Совокупная награда эпизода формируется как взвешенная сумма указанных компонентов:

$$R = \alpha \cdot R_{\text{rel}} - \beta \cdot R_{\text{over}} - \gamma \cdot R_{\text{var}},$$

где R_{rel} — суммарная релевантность фактически выбранных пользователями ресурсов; R_{over} — мера переполнения, агрегированная по тайм-слотам как сумма превышений вместимостей в долях от соответствующих лимитов; R_{var} — дисперсия заполненности ресурсов, агрегированная по тайм-слотам; α, β, γ — неотрицательные весовые коэффициенты, определяющие относительную приоритетность компонентов. Конкретные значения коэффициентов определяются на этапе настройки и приводятся в главе 4.

2.1.6 Постановка как марковский процесс принятия решений с ограничениями

Описанная задача формализуется как марковский процесс принятия решений с ограничениями (Constrained MDP) в смысле, рассмотренном в подразделе 1.3.4. На каждом шаге t управляющий агент наблюдает состояние s_t, включающее текущего обслуживаемого пользователя, его профиль, агрегированные характеристики уже обработанных пользователей и текущую загрузку ресурсов; выбирает действие $a_t = L_{i,t}$ — ранжированный список из K ресурсов; получает мгновенную награду r_t, определяемую вкладом тайм-слота в совокупную награду R; и переходит в новое состояние s_{t+1}, отражающее последствия выбора пользователя. Целью является нахождение стационарной политики π^*, максимизирующей ожидание совокупной награды по эпизоду.

Существенное замечание о форме ограничений вместимости. В представленной выше совокупной награде ограничения заданы через штрафные слагаемые $-\beta R_{\text{over}}$ и $-\gamma R_{\text{var}}$, что соответствует мягкой постановке ограничений в ожидании по политике. Эта форма стандартна

для практических реализаций обучения с подкреплением и сохраняет обучаемость политики, однако формально допускает редкие нарушения вместимости в отдельных реализациях эпизода. Жёсткое соблюдение ограничений в каждой коллективной выдаче, заявленное в подразделах 1.2 и 1.5 как требование к решению, в рамках обучаемой политики достигается комбинацией двух механизмов. Первый — маскирование действий: на этапе формирования рекомендательного списка $L_{i,t}$ из множества кандидатов исключаются ресурсы, заполненность которых превысила пороговую долю вместимости. Маскирование действует на каждом шаге политики и операционально перекрывает грубые случаи переполнения, сводя их вероятность к нулю в пределе порога. Второй — двойственная оптимизация по Лагранжу в рамках constrained policy optimization [Achiam et al., 2017]: множитель β при штрафе за переполнение не фиксируется заранее, а адаптируется в ходе обучения по правилу, увеличивающему β при систематическом нарушении ограничения и уменьшающему при его строгом соблюдении. Сочетание маскирования и адаптации множителя удерживает поведение политики вблизи feasible-области выдач при сохранении дифференцируемой формы целевой функции. Алгоритмическая реализация обоих механизмов приведена в главе 3.

2.1.7 Связь с играми с перегрузкой

Структурная природа задачи соответствует концепции игр с перегрузкой (congestion games) в смысле подраздела 1.3.2. Пользователи представляют автономных агентов, выбирающих ресурсы из предложенных вариантов; полезность ресурса для конкретного пользователя содержит компонент, зависящий от числа других пользователей, выбравших тот же ресурс (через ограничение вместимости и связанные с ним эффекты). В отсутствие управляющего вмешательства система движется к равновесию эгоистичных агентов, отдалённому от системного оптимума на величину, измеряемую показателем «цена анархии». Управляющая политика π выступает в роли информационного сигнала, формирующего издержки альтернативных выборов в восприятии каждого пользователя и тем самым смещающего равновесие в направлении системно-оптимального распределения.

Предлагаемая постановка, таким образом, объединяет аппарат двух рамок: постановка задачи как Constrained MDP обеспечивает операциональный

механизм построения и обучения управляющей политики, а трактовка через игру с перегрузкой — концептуальное обоснование необходимости совместной оптимизации рекомендаций между пользователями и теоретическую интерпретацию роли управляющей политики как механизма коррекции децентрализованного равновесия.

2.2 Требования к решению

На основании постановки задачи (подраздел 2.1) и анализа ограничений существующих подходов (подраздел 1.5) ниже сформулированы требования к разрабатываемому решению, разделённые на три группы: функциональные требования, нефункциональные требования и ограничения предметной области.

2.2.1 Функциональные требования

К числу функциональных требований к разрабатываемому решению относятся:

1) **Приём входных данных.** Система должна принимать на вход множество ресурсов с описаниями и вместимостями, а также множество пользователей с профилями интересов. Представление профилей и описаний должно поддерживать численное вычисление меры близости.
1) **Формирование персональных рекомендаций.** Для каждого пользователя в каждом тайм-слоте система должна формировать ранжированный список из K ресурсов, упорядоченных по предсказанной полезности с учётом текущего состояния системы.
1) **Учёт ограничений вместимости.** Формирование рекомендаций должно учитывать вместимости ресурсов и текущую их заполненность; политика рекомендаций должна избегать систематического направления пользовательского потока к ресурсам, для которых превышение вместимости становится вероятным.
1) **Согласованность рекомендаций между пользователями.** Рекомендация, выдаваемая одному пользователю, должна формироваться с учётом рекомендаций, выданных и реализованных другими пользователями в текущем тайм-слоте.
1) **Обработка вероятностного отклика.** Система должна корректно обрабатывать стохастический характер пользовательского отклика,

включая возможность выбора ресурса вне рекомендательного списка и отказа от выбора в тайм-слоте.

1) **Обновление состояния по фактическим выборам.** Состояние системы, наблюдаемое политикой, должно обновляться по реализованным пользовательским выборам, а не по выданным рекомендациям.
1) **Поддержка сравнения нескольких политик.** Система должна поддерживать прозрачное сравнение различных рекомендательных политик на одной и той же среде с использованием единого набора метрик.

2.2.2 Нефункциональные требования

К числу нефункциональных требований относятся:

1) **Воспроизводимость.** Прогон системы при фиксированных входных данных и параметрах среды должен давать одинаковый результат, что достигается фиксацией начальных значений генераторов случайных чисел и явной спецификацией всех параметров эксперимента.
1) **Эффективность обучения.** Обучение и сравнение политик должны быть осуществимы в разумное время на доступном исследовательском оборудовании уровня одной графической вычислительной карты потребительского класса.
1) **Расширяемость.** Архитектура решения должна поддерживать добавление новых рекомендательных политик и новых функций отклика пользователей без переработки симуляционной среды и компонентов оценки качества.
1) **Прозрачность.** Все компоненты совокупной награды и итоговые метрики должны допускать содержательную интерпретацию в терминах задачи, что необходимо как для отладки, так и для последующего обоснования результатов работы.
1) **Низкая стоимость обучения.** Затраты на обучение и сравнение политик не должны существенно зависеть от стоимости обращения к большим языковым моделям. Использование больших языковых моделей допускается на этапах, требующих однократных или редких обращений, но не на каждом шаге обучения.
1) **Внешняя валидность результатов.** Качество результирующих политик должно подтверждаться не только в среде, в которой проходило обучение,

но и в независимой среде с альтернативной моделью пользовательского поведения; это даёт контроль над расхождениями между двумя моделями симуляции.

2.2.3 Ограничения предметной области

Дополнительно фиксируются ограничения, определяющие условия, в которых решение должно сохранять работоспособность:

1) **Малый каталог ресурсов.** Число рассматриваемых ресурсов исчисляется десятками (в частности, для конференций Mobius и Heisenbug 2023–2025 годов — порядка 30–40 докладов на одну конференцию), что исключает применение методов, требующих больших каталогов для устойчивого обучения базовых моделей релевантности.
1) **Отсутствие журналов реальных пользовательских взаимодействий.** Решение должно поддерживать обучение и сравнение политик в условиях отсутствия исторических данных о фактических пользовательских выборах; доступны лишь публичные программы конференций (тематики, форматы, тайм-слоты, вместимости залов).
1) **Ограниченный бюджет вычислений и обращений к большим языковым моделям.** Объём обучающих и оценочных вычислений ограничен ресурсами одного исследователя; объём обращений к большим языковым моделям — соответствующим бюджетом.

Совокупность сформулированных требований формирует основу для описания предлагаемого метода в подразделе 2.3.

2.3 Описание предлагаемого метода

Предлагаемый метод объединяет три компонента: гибридную симуляционную среду для обучения и оценки политик при отсутствии исторических данных; набор сравниваемых рекомендательных политик различной природы — от случайной до обучаемой методами обучения с подкреплением и основанной на большой языковой модели; двухслойную схему валидации с операциональной проверкой в обучающей среде и независимой проверкой в среде с альтернативной моделью пользовательского поведения. Каждый компонент отвечает за подмножество требований из подраздела 2.2.

2.3.1 Гибридная симуляционная среда

Симуляционная среда, в которой осуществляется обучение и сравнение рекомендательных политик, имеет двухкомпонентную структуру.

Компонент однократной генерации пользовательской популяции. Перед началом обучения большая языковая модель формирует синтетическую популяцию пользователей в количестве, достаточном для статистически значимого сравнения политик. Каждый пользователь характеризуется текстовым профилем интересов, отражающим его предметные предпочтения, уровень квалификации, тематическую специфику и иные характеристики, влияющие на пользовательский выбор. Сгенерированные профили преобразуются в векторные эмбеддинги, согласованные по размерности с эмбеддингами описаний ресурсов. Однократный характер обращения к большой языковой модели существенно снижает совокупную стоимость экспериментов по сравнению со схемами, в которых обращение к большой языковой модели выполняется на каждом шаге обучения, при сохранении содержательного разнообразия пользовательской популяции. Использование большой языковой модели в роли генератора синтетических данных описано в подразделе 1.4.4 как одно из основных направлений применения языковых моделей в задачах рассматриваемого класса.

Компонент параметрического пошагового симулятора. Основной цикл обучения и оценки политик реализуется параметрическим симулятором, разыгрывающим на каждом шаге функцию выбора пользователей. Функция выбора реализуется мультиномиальной логит-моделью с температурой, описанной в подразделе 2.1, и зависит от релевантности предложенных ресурсов профилю пользователя, текущей заполненности ресурсов и базовой склонности пользователя к отказу от участия в тайм-слоте. Параметры функции выбора (температура, штраф за заполненность, базовая вероятность отказа) фиксируются на этапе настройки симулятора. Параметрическая природа компонента даёт высокую скорость симуляции, воспроизводимость результатов при фиксации начальных значений генератора случайных чисел и независимость стоимости обучения от стоимости обращений к большой языковой модели.

Гибридная структура среды отвечает требованию низкой стоимости обучения (нефункциональное требование 5) при сохранении

содержательного разнообразия популяции, недостижимого в чисто параметрических симуляторах. Кроме того, она удовлетворяет требованиям воспроизводимости и эффективности (нефункциональные требования 1 и 2).

2.3.2 Множество сравниваемых рекомендательных политик

В рамках предлагаемого метода рассматриваются шесть рекомендательных политик различной природы, дающих основу для систематического сравнения подходов к решению задачи. Каждая политика реализует отображение текущего состояния системы и профиля обслуживаемого пользователя в ранжированный список из K ресурсов.

Политики 1–4 — детерминированные эвристики разной природы, не требующие обучения; их назначение в составе сравнения — сформировать спектр базовых линий разной сложности, относительно которых оценивается вклад обучаемых подходов (политики 5 и 6).

| Политика | Механизм | Назначение | |—|—|—| | **1. Случайный выбор** | равномерно случайные K ресурсов из каталога без учёта профиля и состояния | нижняя планка качества; контроль адекватности постановки и метрик | | **2. Косинусная близость** | top-K по убыванию косинусной близости профиля и описаний ресурсов | точка отсчёта без учёта вместимости и взаимосвязанности рекомендаций | | **3. Косинусная близость с учётом вместимости** | мультипликативный штраф к релевантности по текущей заполненности; ресурсы выше порога исключаются | минимальный эвристический учёт ограничений вместимости без обучения | | **4. Maximal Marginal Relevance** | алгоритм MMR (подраздел 1.4.1) с параметром λ баланса релевантности и разнообразия | классический академический подход к повышению тематического разнообразия выдачи |

Политика 5: Обучаемая политика на основе обучения с подкреплением. Реализуется методом проксимальной оптимизации политики (PPO), описанным в подразделе 1.4.2, с маскированием действий и двойственной оптимизацией множителя β согласно подразделу 2.1. Обучается в параметрическом симуляторе на совокупной награде. Состояние, наблюдаемое политикой, включает профиль текущего обслуживаемого пользователя, текущую заполненность ресурсов и агрегированные характеристики уже обработанных пользователей; действие —

ранжированный список из K ресурсов. Эта политика — центральный сравнительный объект работы; архитектурные детали актора и критика, а также гиперпараметры обучения приводятся в главе 3.

Политика 6: LLM-ranker. Реализует подход, в котором большая языковая модель выступает в роли ранжирующего компонента. Модель получает на вход профиль пользователя, описания ресурсов из числа N ресурсов с наибольшей косинусной близостью к профилю и сводку текущей заполненности залов; на выходе формирует ранжированный список из K ресурсов с учётом всех представленных факторов. Соответствует подходу, описанному в подразделе 1.4.4 как одно из основных направлений применения больших языковых моделей в задачах рассматриваемого класса. Назначение — сравнение с современным альтернативным методом, представляющим парадигму непосредственного использования больших языковых моделей в качестве рекомендательного компонента.

Совокупность шести политик покрывает основные классы подходов, рассмотренные в подразделах 1.3 и 1.4: случайный выбор как формальная нижняя граница; чистое контентное ранжирование как классический recsys-подход без ограничений; правиловое управление с учётом ограничений; классический алгоритм диверсификации; обучаемая политика в постановке Constrained MDP; современный подход на основе большой языковой модели. Такой охват даёт систематическое сравнение и позволяет позиционировать обучаемую политику относительно как простых эвристик, так и современных альтернатив.

2.3.3 Двухслойная схема валидации

Внешнюю валидность результатов поддерживает двухслойная схема проверки, разделяющая этап обучения и сравнения политик и этап независимой проверки результата.

Слой 1: основное сравнение в параметрическом симуляторе. Все шесть политик обучаются (для политик 5 и 6 — настраиваются) и сравниваются в гибридной симуляционной среде, описанной выше. На этом слое реализуется протокол сравнения по совокупности метрик, определяемых в подразделе 2.5, и выполняется выбор лучшей политики по совокупному критерию. Среда первого слоя характеризуется высокой скоростью, воспроизводимостью и низкой стоимостью.

Слой 2: дополнительная валидация лучшей политики в LLM-агентной среде. Политика, признанная лучшей по результатам первого слоя, проходит дополнительную проверку в среде, в которой пользователи моделируются не параметрической мультиномиальной логит-моделью, а автономными агентами на основе больших языковых моделей с собственной памятью и функцией выбора, как описано в подразделе 1.4.4 со ссылкой на работу Agent4Rec. Среда второго слоя характеризуется существенно большей вычислительной стоимостью, что ограничивает её применение этапом итоговой проверки. Сопоставление результатов первого и второго слоёв даёт оценку устойчивости выбранной политики к смене модели пользовательского поведения и содержательную интерпретацию расхождений между двумя альтернативными моделями симуляции. При этом методологически следует учитывать риск общего источника синтетики: оба слоя опираются на пользовательские профили, сгенерированные большой языковой моделью, и систематическое согласие двух слоёв может частично объясняться общим источником, а не корректностью обеих моделей; для контроля этого риска во втором слое предусмотрена возможность независимой генерации профилей и поведенческой модели от моделей разных семейств.

Двухслойная схема отвечает требованию внешней валидности результатов: разделение слоёв по стоимости совмещает требование внешней валидности и требование низкой стоимости обучения, которые в одноуровневой схеме противоречат друг другу.

2.4 Сравнительный анализ альтернатив

Помимо предлагаемого метода, описанного в подразделе 2.3, существуют альтернативные методологические подходы, опирающиеся на другие концептуальные рамки из числа рассмотренных в подразделе 1.3 либо на иные конфигурации симуляционных сред. Настоящий подраздел проводит сравнительный анализ четырёх альтернатив с предлагаемым методом и обосновывает выбор последнего.

2.4.1 Альтернатива 1. Чисто оптимизационный подход в рамках исследования операций

Первая альтернатива — формулировка задачи как обобщённой задачи о назначениях (GAP) или многопериодной задачи о назначениях, рассмотренной в подразделе 1.3.1, с последующим её решением точными методами целочисленного программирования или приближёнными эвристиками. Этот подход даёт строгую математическую постановку и развитый алгоритмический арсенал.

Препятствие для использования этой альтернативы как основного метода — фундаментальное допущение классической постановки задач о назначениях: решение управляющей стороны полагается исполнимым. В рассматриваемой задаче решение имеет статус рекомендации, которой пользователь может не следовать; прямое применение GAP даёт решения, оптимальные в детерминированной модели, но потенциально неоптимальные с учётом вероятностного отклика.

2.4.2 Альтернатива 2. Чисто теоретико-игровой подход

Вторая альтернатива — описание задачи как игры с перегрузкой в рамках теоретико-игровой рамки подраздела 1.3.2 с последующим аналитическим вычислением равновесия Нэша или равновесия Уордропа, а также показателя «цена анархии» для системы. Подход опирается на развитую теорию и даёт концептуально чистое описание ситуации децентрализованного выбора автономных агентов.

Препятствие — описательный, а не предписывающий характер классической теоретико-игровой рамки: аппарат равновесий отвечает на вопрос, какое распределение установится при заданных правилах, но не даёт алгоритма построения управляющего воздействия. В работе теоретико-игровая рамка используется как структурное обоснование необходимости совместной оптимизации (подраздел 2.1); операциональным методом построения политики служит аппарат марковского процесса принятия решений с ограничениями.

2.4.3 Альтернатива 3. Прямое обучение в LLM-агентной среде

Третья альтернатива — использование LLM-агентной симуляционной среды (подраздел 1.4.4) в качестве основной среды обучения рекомендательной

политики, без параметрического симуляционного слоя. Такая среда даёт максимальную содержательную глубину пользовательского поведения: каждый пользователь моделируется как автономный агент на основе большой языковой модели с собственной памятью и функцией выбора.

Препятствие — вычислительная стоимость: обучение методами обучения с подкреплением требует миллионов шагов, каждый из которых в LLM-агентной среде влечёт множественные обращения к большой языковой модели, что выводит совокупный бюджет за пределы доступных ресурсов.

2.4.4 Альтернатива 4. Прямое применение классических методов рекомендательных систем с ограничениями

Четвёртая альтернатива — прямое применение методов рекомендательных систем с ограничениями, описанных в подразделе 1.3.3, в первую очередь постановки ранжирования с ограничениями Сингха и Йоахимса. Эти методы дают формальный аппарат и алгоритмы оптимизации политики ранжирования при дополнительных ограничениях на агрегированную экспозицию ресурсов.

Препятствие — принципиальное отличие в типе формулируемого ограничения. Классические методы рекомендательных систем с ограничениями формулируют их как математическое ожидание по распределению пользователей, что подразумевает выравнивание совокупной экспозиции ресурсов «в среднем» по большому потоку независимых выдач. В рассматриваемой постановке ограничения вместимости должны соблюдаться в каждой конкретной коллективной выдаче, формируемой одновременно для фиксированного множества пользователей. Адаптация классических методов под подобный режим работы требует существенной методологической переработки, по объёму сопоставимой с разработкой нового метода.

Ни одна из четырёх альтернатив, взятая отдельно, не закрывает совокупности требований к решению; предлагаемый метод — синтез элементов нескольких рамок, описанный в подразделе 2.3. Отдельные методы переранжирования из 1.4.1 включены в состав сравниваемых политик (политика 4, MMR).

2.5 Дизайн экспериментов и план валидации

Настоящий подраздел определяет дизайн экспериментальной части работы, направленной на сравнительную оценку шести политик, описанных в подразделе 2.3, и независимую валидацию лучшей политики во втором слое симуляционной среды. Экспериментальная часть включает четыре составляющие: сравнение политик по основным метрикам качества, исследования влияния отдельных компонентов метода (ablation studies), проверку устойчивости результатов к вариации параметров среды и итоговую валидацию в LLM-агентной среде. Все экспериментальные процедуры опираются на единый набор метрик, описанный в первой части подраздела.

2.5.1 Основные метрики оценки

Сравнение рекомендательных политик опирается на четыре метрики, каждая из которых отражает отдельный аспект качества решения.

Overflow rate. Относительная мера переполнений ресурсов. Для каждого ресурса в каждом тайм-слоте вычисляется превышение фактического числа пользователей над вместимостью, отнесённое к вместимости; итоговое значение — среднее этих превышений по всем ресурсам, тайм-слотам и эпизодам. Метрика принимает значения от нуля (вместимости соблюдаются строго) до положительных значений, растущих с увеличением степени переполнения. Отражает соблюдение жёстких ограничений вместимости в каждой одноразовой выдаче.

Hall utilization variance. Дисперсия относительной заполненности ресурсов в пределах тайм-слота, усреднённая по тайм-слотам и эпизодам. Низкие значения метрики соответствуют равномерному распределению аудитории между ресурсами; высокие значения — ситуации одновременной перегрузки части ресурсов и недозагрузки других. Отражает согласованность рекомендаций, выдаваемых разным пользователям одновременно.

Mean user utility. Средняя релевантность ресурсов, фактически выбранных пользователями в ходе эпизода. Релевантность измеряется как косинусная близость профиля пользователя и описания выбранного ресурса (подраздел 2.1); пользователи, отказавшиеся от выбора в тайм-слоте, вносят нулевой вклад в среднее. Метрика отражает суммарную пользовательскую полезность, достигнутую политикой.

Gini coefficient по ресурсам. Коэффициент Джини, рассчитанный

по совокупному распределению аудитории между ресурсами за эпизод, отражающий неравенство получаемого ресурсами внимания. Близкие к нулю значения соответствуют равномерному распределению аудитории; близкие к единице — ситуации, в которой большая часть пользователей сосредоточена на малом числе ресурсов. Метрика отражает справедливость со стороны поставщиков ресурсов в смысле, рассмотренном в подразделе 1.3.3.

Совокупность четырёх метрик покрывает три аспекта качества: соблюдение системных ограничений (Overflow rate, Hall utilization variance), пользовательская полезность (Mean user utility), справедливость распределения внимания между ресурсами (Gini coefficient). Раздельное представление метрик позволяет анализировать компромиссы, возникающие между конкурирующими аспектами качества.

2.5.2 Протокол сравнения политик

Сравнение шести политик из подраздела 2.3 проводится в первом слое симуляционной среды по следующему протоколу.

В качестве экспериментальной обстановки фиксируется конкретная конфигурация среды: множество ресурсов с заданными описаниями и вместимостями, синтетическая популяция пользователей, сформированная однократной LLM-генерацией, расписание тайм-слотов. Все шесть политик прогоняются в идентичной среде; различие между прогонами определяется только начальным значением генератора случайных чисел, управляющего стохастикой функции выбора.

Каждая политика оценивается на множестве независимых эпизодов количества n_{ep}, отличающихся начальным значением случайных чисел. Для обучаемых политик (политика 5) обучение выполняется отдельно с использованием фиксированной части эпизодов, оценка — на отдельной отложенной выборке, что гарантирует корректное разделение обучающих и оценочных данных. Для каждой метрики вычисляются среднее и доверительный интервал по эпизодам.

Сравнение результатов проводится по двум критериям. Первый критерий — раздельное сравнение по каждой из четырёх метрик; политики ранжируются по каждой метрике с указанием статистической значимости различий. Второй критерий — совокупное сравнение по взвешенной сумме компонентов совокупной награды, определённой в подразделе 2.1;

этот критерий используется для выбора лучшей политики при наличии компромиссов между метриками.

2.5.3 Исследование влияния отдельных компонентов и устойчивости

В дополнение к основному сравнению политик в главе 4 проводятся исследования влияния отдельных компонентов метода (ablation studies) и проверка устойчивости результатов к вариации параметров среды; конкретный объём и сценарии определяются по итогам основного сравнения.

2.5.4 Итоговая валидация во втором слое

Лучшая политика по результатам первого слоя проходит независимую валидацию во втором слое симуляционной среды на основе LLM-агентов, описанной в подразделе 2.3. Протокол валидации включает прогон политики на ограниченном числе эпизодов в среде, в которой пользователи моделируются автономными агентами на основе больших языковых моделей с собственной памятью и функцией выбора.

В рамках второго слоя рассчитываются те же четыре метрики, что и в первом, и проводится их сопоставление с результатами первого слоя. Отдельное внимание уделяется качественному анализу расхождений: сценариям, в которых результаты двух слоёв существенно различаются. Анализ даёт оценку устойчивости выбранной политики к смене модели пользовательского поведения и формирует материал для обсуждения границ внешней валидности результатов работы.

2.5.5 Критерии успешности работы

Цель экспериментальной части — получить количественную характеристику компромиссов между соблюдением системных ограничений и пользовательской полезностью для шести политик различной природы и оценить устойчивость наблюдаемых компромиссов к смене модели пользовательского поведения через переход во второй слой валидации. Любой из возможных исходов сравнения — подтверждение преимущества обучаемой политики, преимущество эвристических подходов либо паритет — рассматривается как самостоятельный результат, имеющий содержательную интерпретацию и определяющий направление дальнейших исследований.

2.6 Выводы по главе

Задача формирования согласованных рекомендательных выдач при ограничениях вместимости формализована как марковский процесс принятия решений с ограничениями в структуре игры с перегрузкой. Состояние политики включает текущую загрузку ресурсов, что определяет совместность рекомендаций между пользователями; функция релевантности задана через косинусную близость эмбеддингов профилей и описаний; отклик пользователей моделируется как случайная величина с возможностью отказа от выбора; награда — взвешенная сумма пользовательской полезности, штрафа за переполнение и штрафа за неравномерность загрузки.

Предлагаемый метод объединяет гибридную симуляционную среду (однократная LLM-генерация пользовательской популяции и параметрический пошаговый симулятор), шесть сравниваемых рекомендательных политик различной природы и двухслойную схему валидации с проверкой лучшей политики во второй симуляционной среде на основе LLM-агентов. Постановка задачи как марковского процесса принятия решений с ограничениями делает применимым метод проксимальной оптимизации политики в схеме «актор-критик» с двойственной оптимизацией множителей Лагранжа, учитывающий ограничения вместимости в составе обучаемой политики. Рассмотренные в подразделе 2.4 альтернативные методологические подходы — чистый оптимизационный, теоретико-игровой, прямое обучение в LLM-агентной среде и прямое применение методов рекомендательных систем с ограничениями — каждый по отдельности не закрывает совокупности требований; предлагаемый синтез даёт содержательный ответ на эту совокупность.

Дизайн экспериментальной части включает сравнение политик по четырём метрикам качества (Overflow rate, Hall utilization variance, Mean user utility, Gini coefficient), исследования влияния отдельных компонентов метода, проверку устойчивости результатов к вариации параметров среды и итоговую валидацию во втором слое симуляционной среды. Технические решения по реализации и результаты экспериментов представлены в главах 3 и 4.

ЗАКЛЮЧЕНИЕ

Заключение работы оформляется по итогам экспериментальной части и приводится в финальной версии выпускной квалификационной работы.